UNIVERSIDAD NACIONAL DE INGENIERÍA

Unidad de Posgrado · Facultad de Ingeniería Industrial y de Sistemas

INFORME PARCIAL

Proyecto de Investigación II · Plan de tesis y protocolo de investigación

Sistema de Tutoría Inteligente Adaptativa para Comprensión Lectora mediante Deep Reinforcement Learning Integrado con MSKT y NeuralCD: Un Enfoque Basado en Literatura Peruana

Tipo de tesis: Académica (Maestría en Inteligencia Artificial)

GRUPO 2 Flores Rivera, Amit Roy · Urrego Montoya, Yasmin

ASESORA Mg. Ing. María Fernanda Tejada Begazo

DOCENTE DEL CURSO Dr. Glen Dario Rodríguez Rafael

CORTE Semana 9 · Lima, 13 de noviembre de 2026

EN UNA PÁGINA

Resumen

El plan de tesis propone un tutor adaptativo de comprensión lectora que decide qué texto asignar mediante aprendizaje por refuerzo. La arquitectura objetivo combina seguimiento de conocimiento (MSKT), diagnóstico cognitivo (NeuralCD) y planificación basada en modelo (Dyna-PPO). **Al corte de la Semana 9 está ejecutado y versionado un prototipo más pequeño:** un simulador IRT-3PL con olvido, un agente PPO lineal y un estudio de ingeniería de variables con validación cruzada por estudiante.

−0.0095 → +0.0203

Ganancia por episodio: vector crudo → vector depurado

+0.0298

Diferencia pareada · IC 95 % [+0.0225, +0.0372] · 10/10 corridas

49 %

de la ganancia de la heurística con oráculo (+0.0411)

Dyna-PPO, la búsqueda de hiperparámetros y los estimadores MSKT/NeuralCD **no están ejecutados** y se planifican para las Semanas 10–16. Todas las conclusiones se limitan a estudiantes sintéticos.

Índice

Resumen 2

Índice 3

PARTE I. Plan de tesis 4

Capítulo I. Planteamiento del problema 4

Capítulo II. Objetivos 5

Capítulo III. Marco teórico 6

Capítulo IV. Diseño metodológico 7

Capítulo V. Administración del plan 8

PARTE II. Protocolo y avance experimental 9

6. Datos y material de estudio 9

7. Protocolo experimental 9

8. Resultados parciales y evidencia 10

9. Conclusiones y próximos pasos 12

Referencias 13

Anexos 15

Anexo A. Matriz de consistencia 15

Anexo B. Enlace al último branch y trazabilidad 15

Anexo C. Variables 15

Anexo D. Registro de corridas 16

Anexo E. Pruebas de no-fuga 16

PARTE I. Plan de tesis

Datos generales

Tabla 1. *Datos generales del plan de tesis.*

Campo	Información
Título	Sistema de Tutoría Inteligente Adaptativa para Comprensión Lectora mediante Deep Reinforcement Learning Integrado con MSKT y NeuralCD: Un Enfoque Basado en Literatura Peruana
Autores (Grupo 2)	Flores Rivera, Amit Roy · Urrego Montoya, Yasmin
Asesora	Mg. Ing. María Fernanda Tejada Begazo
Docente del curso	Dr. Glen Dario Rodríguez Rafael
Programa	Maestría en Inteligencia Artificial, Unidad de Posgrado FIIS-UNI
Infraestructura	Equipos personales (CPU) y repositorio GitHub yasminum/SistemaTutorInteligente. Estudio in-silico.
Duración	16 semanas académicas; corte de este informe: Semana 9 (13/11/2026)

Capítulo I. Planteamiento del problema

1.1 Diagnóstico

En PISA 2022, solo el 50 % de los estudiantes peruanos de 15 años alcanzó al menos el Nivel 2 de lectura, frente al 74 % del promedio OCDE (OECD, 2023). Las brechas se concentran en las capacidades inferencial y crítica del Currículo Nacional (MINEDU, 2016).

- **Síntoma:** el estudiante recibe textos demasiado fáciles o demasiado difíciles para su nivel, y el aprendizaje se estanca.
- **Causa técnica:** los tutores con secuencias fijas no adaptan la dificultad al estado del estudiante; los que optimizan el acierto inmediato tienden a asignar material fácil (Doroudi et al., 2019).
- **Consecuencia:** falta una política de secuenciación validada en simulación antes de cualquier prueba con escolares.

1.1.1 Problema de estudio

Diseñar y evaluar en simulación una política que elija, en cada uno de los T = 50 pasos de una sesión, el texto cuya dificultad mejor se acopla a la habilidad del estudiante en tres competencias lectoras (literal, inferencial y crítica).

1.1.2 Antecedentes

Seguimiento de conocimiento. BKT (Corbett & Anderson, 1994), DKT (Piech et al., 2015), SAKT (Pandey & Karypis, 2019) y SAINT+ (Shin et al., 2021) predicen el acierto futuro, pero no prescriben qué asignar. MSKT es el estimador de conocimiento previsto en la arquitectura objetivo.

Diagnóstico cognitivo. NeuralCD (Wang et al., 2020) estima un perfil de dominio interpretable por competencia.

Secuenciación con RL. Doroudi et al. (2019) revisan el RL para secuenciación instruccional y reportan resultados mixtos, sensibles al modelo de estudiante. PPO (Schulman et al., 2017) es el algoritmo base; Dyna (Sutton, 1991) y MBPO (Janner et al., 2019) fundamentan la planificación con modelo prevista.

1.1.3 Formulación del problema

Problema general. ¿En qué medida una política de aprendizaje por refuerzo, alimentada con variables depuradas de acoplamiento habilidad–dificultad, mejora la ganancia de aprendizaje simulada frente a políticas base en un entorno IRT-3PL?

PE1. ¿Cuánto aportan las variables de acoplamiento (zpd_hit, abs_gap) a predecir la transición de aprendizaje y a la ganancia de la política?

PE2. ¿Mejora la ganancia al eliminar columnas sin información y variables colineales del estado?

PE3. ¿Mejora la ganancia y la eficiencia muestral al añadir planificación con modelo (Dyna-PPO) y ajuste de hiperparámetros? (Planificado; sin evidencia al corte.)

1.2 Justificación y alcances

Justificación. Metodológica: un protocolo reproducible de selección de variables con validación por estudiante y pruebas de no-fuga. Práctica: una base de software verificable antes de exponer a escolares. Social: orientación al currículo peruano de 3.er grado de secundaria.

Alcances. (a) Estudio estrictamente in-silico; ninguna conclusión se extiende a estudiantes reales. (b) El banco actual es paramétrico: 30 textos × 10 ítems con parámetros IRT muestreados (bank_seed = 2026); vincularlo con textos de narrativa peruana es trabajo planificado. (c) El agente observa la habilidad verdadera del simulador; sustituirla por estimadores aprendidos (MSKT, NeuralCD) es trabajo planificado.

Capítulo II. Objetivos

Objetivo general. Desarrollar y evaluar en simulación una política de secuenciación adaptativa de textos basada en aprendizaje por refuerzo que maximice la ganancia de aprendizaje en comprensión lectora.

Tabla 2. *Objetivos específicos y su estado.*

Objetivo específico	Descripción	Estado al corte
OE1	Determinar el aporte de las variables de acoplamiento ZPD.	Ejecutado

Objetivo específico	Descripción	Estado al corte
OE2	Evaluar el efecto de depurar el estado (columnas muertas y colinealidad).	Ejecutado; no concluyente
OE3	Evaluar Dyna-PPO, ajuste de hiperparámetros y estimadores MSKT/NeuralCD.	Planificado (Sem. 10–16)

Capítulo III. Marco teórico

3.1 Bases teóricas

Comprensión lectora e IRT-3PL. Siguiendo a Kintsch (1998) y al CNEB, se modelan K = 3 competencias. La probabilidad de acierto sigue el modelo de tres parámetros (Birnbaum, 1968): $P = c + (1 - c) / (1 + \exp(-1.7 \cdot a \cdot (\theta - b)))$, con $a \sim U(0.8, 2.0)$, $b \sim N(0, 1)$ y $c = 0.25$.

Zona de desarrollo próximo. El simulador incrementa la habilidad solo cuando $|\theta - b| < 0.5$ y la respuesta es correcta (Vygotsky, 1978; Csikszentmihalyi, 1990), y aplica olvido exponencial a las competencias no ejercitadas.

PPO. Gradiente de política con objetivo recortado y ventaja generalizada (Schulman et al., 2016, 2017). El prototipo usa una política lineal.

Planificación con modelo y seguridad (diseño). Dyna (Sutton, 1991; Sutton & Barto, 2018) con rollouts cortos (Janner et al., 2019) y restricciones de seguridad tipo CMDP (Altman, 1999; García & Fernández, 2015) forman parte de la arquitectura objetivo, aún no implementada.

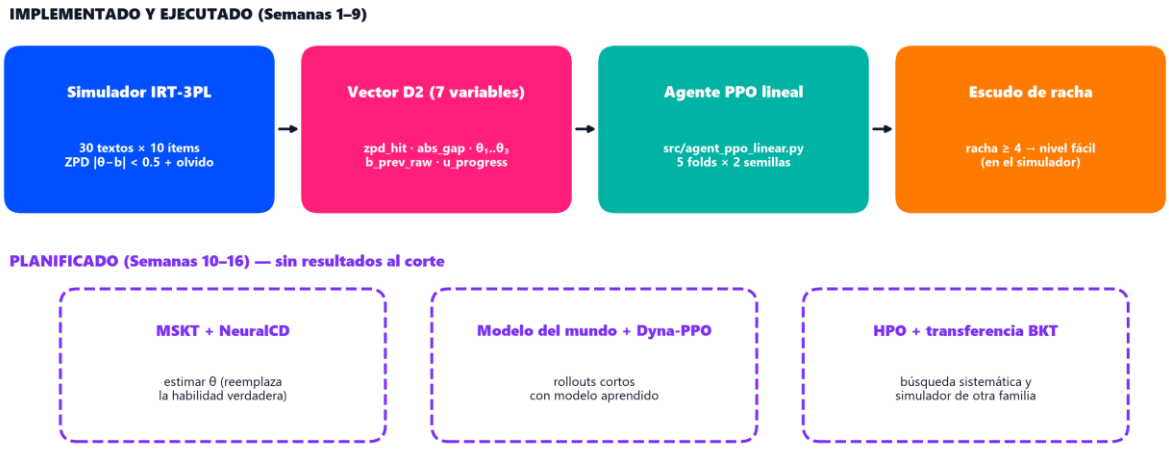


Figura 1. *Arquitectura: bloques implementados (arriba) y planificados (abajo, línea discontinua). La figura no contiene cifras de resultados.*

3.2 Definición de términos

- **LG (ganancia normalizada; Hake, 1998):** (θ_final − θ_inicial) / (1 − θ_inicial), medida sobre la habilidad verdadera en una sesión de 50 pasos con alumnos no vistos.
- **zpd_hit:** indicador $1[|\theta_k - b| < 0.5]$ para el texto candidato. **abs_gap:** $|\theta_k - b|$.

- **Referencia de oráculo:** heurística que conoce θ verdadero y elige el texto con mayor zpd_hit (LG = +0.0411).

3.3 Hipótesis y variables

> **Enmienda al protocolo**
>
> El umbral original LG ≥ 0.50 se retira: el propio simulador acota la ganancia de una sesión en 0.3255 (acierto en ZPD en los 50 pasos) y la heurística con oráculo logra +0.0411. Las hipótesis se reformulan en términos de diferencias pareadas y de fracción del oráculo.

Tabla 3. *Hipótesis y estado de contrastación.*

Hipótesis	Enunciado	Estado al corte
HG	PPO con el vector depurado de 7 variables supera a PPO con el vector crudo y a las políticas aleatoria y de currículo fijo.	Respaldada de forma exploratoria. Criterio confirmatorio propuesto (a fijar con la asesora antes de ejecutar): particiones y semillas nuevas, IC 95 % sin incluir 0 y ≥ 40 % del oráculo.
HE1	zpd_hit y abs_gap son las dos variables más informativas del vector.	Parcialmente confirmada.
HE2	Depurar el estado mejora la ganancia frente al vector con 4 variables ZPD.	No confirmada a α = 0.05 (p = 0.0605).
HE3	Dyna-PPO con hiperparámetros ajustados supera a PPO sin modelo.	No evaluada.

Variables independientes: conjunto de variables de estado-acción (FS0, FS2, D1, FS1, D2) y tipo de política.

Variable dependiente: ganancia de aprendizaje simulada.

Indicadores: LG por episodio, diferencia pareada con IC 95 %, p de permutación, d_z, ΔAUC por permutación, |SHAP| y VIF.

Capítulo IV. Diseño metodológico

Tabla 4. *Diseño metodológico.*

Aspecto	Decisión
4.1 Tipo	Investigación aplicada, cuantitativa, experimental computacional (in-silico).
4.2 Nivel	Explicativo dentro del simulador: se manipula el conjunto de variables manteniendo fijos estudiantes, particiones y semillas.
4.3 Método	Sprints semanales versionados en GitHub: EDA, ingeniería de variables, auditoría de datos, importancia de variables.
4.4 Población y muestra	100 estudiantes sintéticos; 5 folds agrupados por estudiante (80 entrenamiento / 20 validación).
4.5 Diseño	Pareado: cada variante se entrena y evalúa en las mismas 10 corridas (5 folds × 2 semillas).
4.6 Instrumentos	Simulador (src/simulator.py), agente (src/agent_ppo_linear.py), experimento (src/experiment.py) y registros JSON/CSV en entrega_sem7/data/results/.

Aspecto	Decisión
4.7 Análisis	Diferencia pareada con IC 95 % bootstrap percentil, prueba exacta de permutación de signos, corrección de Holm (1979), d_z (Cohen, 1988), importancia por permutación, SHAP (Lundberg & Lee, 2017) y VIF.
4.8 Etapas	Cuatro ejecutadas (Semanas 4–7); Semanas 8–9 dedicadas a depurar la evidencia y a este informe; cierre en Semanas 10–16.

Capítulo V. Administración del plan

5.1 Cronograma

Tabla 5. *Cronograma de 16 semanas.*

Semanas	Actividad	Producto verificable	Estado
1–3	Simulador y banco paramétrico	src/simulator.py	Hecho
4	EDA	Rama eda	Hecho
5	Variables ZPD y pruebas de no-fuga	Rama feature-engineering	Hecho
6–7	Auditoría, importancia de variables, matriz de consistencia	summary.json, runs_oracle.json	Hecho
8–9	Depuración de evidencia e informe parcial	Este informe	Hecho
10–11	Modelo del mundo y Dyna-PPO; ablación real	Código y logs por corrida	Planificado
12	Búsqueda de hiperparámetros real	Registro de trials generado por script	Planificado
13–14	Estimador de habilidad aprendido; evaluación confirmatoria	Tabla confirmatoria	Planificado
15–16	Redacción final y sustentación	Informe final, release	Planificado

5.2 Presupuesto y 5.3 Financiamiento

Sin desembolso monetario: software libre y equipos personales. El aporte es en especie (horas de los dos investigadores y uso de equipos). Proyecto autofinanciado.

PARTE II. Protocolo y avance experimental

6. Datos y material de estudio

6.1 Origen. Datos 100 % sintéticos generados por el simulador. Código y resultados en GitHub; rama y commit en el Anexo B.

6.2 Estructura y EDA. 100 estudiantes × 50 pasos por sesión. El vector crudo tiene 13 variables; se añadieron 4 de acoplamiento ZPD. La auditoría encontró 8 columnas sin información (n_dead_xt = 8): cinco marcadores constantes (u_acc, u_streak, tau_1, tau_2, E_hat) y tres de incertidumbre (sigma_1..3) que no varían. Además, zpd_prox y signed_gap son colineales con zpd_hit y abs_gap.

6.3 Ética. No hay datos personales. Cualquier prueba con escolares requerirá comité de ética y consentimiento, fuera del alcance de esta etapa.

6.4 Control de fugas. Partición por estudiante, variables construidas solo con información previa a la acción y transformaciones ajustadas solo en entrenamiento. Resultado registrado: leakage_all_pass = true.

7. Protocolo experimental

7.1 Preguntas. E1: ¿las variables ZPD mejoran la ganancia frente al vector crudo? E2: ¿el historial temporal aporta? E3: ¿la depuración del estado añade mejora? E4: ¿qué ocurre si la habilidad se estima con ruido?

7.2 Particiones. GroupKFold con 5 folds por estudiante (fold_seed = 2026) y 2 semillas de entrenamiento por fold.

7.3 Métricas y estadística. Métrica primaria: LG por episodio en alumnos de validación. Comparación: diferencia pareada frente a FS0 con IC 95 % bootstrap percentil, p exacto de permutación de signos (mínimo alcanzable 2/1024 = 0.00195) y d_z. Limitación declarada: las dos semillas de un mismo fold no son independientes, por lo que los p-valores son aproximados.

Tabla 6. *Políticas y variantes evaluadas (7.4).*

ID	Descripción
Aleatoria / Currículo fijo	Referencias sin aprendizaje
FS0_raw13	PPO lineal con las 13 variables crudas (línea base)
FS2_hist6	FS0 + 6 variables de historial temporal
D1_zpd2	FS0 + zpd_hit y abs_gap
FS1_zpd4	FS0 + 4 variables ZPD
D2_clean5_zpd2	5 variables de estado limpias + zpd_hit y abs_gap (7 variables)

ID	Descripción
Oráculo ZPD	Heurística con θ verdadero (referencia superior)

7.5 Ingeniería de atributos. De 17 candidatas a 7: se descartan 8 columnas muertas y 2 colineales.

7.6 Hiperparámetros. Fijos, sin búsqueda: 1 500 episodios, lr_π = 0.02, lr_V = 0.01, clip = 0.2, entropía = 0.01, γ = 0.99, λ = 0.95. La búsqueda sistemática está planificada.

7.7 Reproducibilidad. Semillas, configuración y huellas SHA-256 del código y los datos en runs_oracle.json; pruebas de no-fuga en tests/test_leakage_checks.py.

8. Resultados parciales y evidencia

8.1 Estado de implementación

Depuración de evidencia

Las cifras de ablación B0–B5 y de optimización de hiperparámetros presentadas en el avance de la Semana 8 (LG entre 0.50 y 0.53) no provenían de corridas ejecutadas sobre el código versionado. Se retiran de este informe junto con sus figuras.

Tabla 7. *Estado de implementación al corte.*

Componente	Estado
Simulador IRT-3PL con ZPD y olvido	Ejecutado
Variables ZPD, auditoría e importancia	Ejecutado
PPO lineal, 10 corridas pareadas	Ejecutado
Modelo del mundo y Dyna-PPO	Planificado
Búsqueda de hiperparámetros	Planificado
MSKT y NeuralCD como estimadores	Planificado

8.2 Comparación cuantitativa

Tabla 8. *Resultados en alumnos no vistos (10 corridas pareadas). Fuente: summary.json y runs_oracle.json.*

Política / vector	LG (media ± DE)	Δ vs FS0 [IC 95 %]	p_perm	d_z	Vict.	Decisión
Aleatoria	−0.0443	—	—	—	—	Referencia
Currículo fijo	−0.0299	—	—	—	—	Referencia
FS0_raw13	−0.0095 ± 0.0174	—	—	—	—	Línea base
FS2_hist6	−0.0063 ± 0.0162	+0.0032 [−0.0051, +0.0122]	0.494	0.22	5/10	Descartada
D1_zpd2	+0.0094 ± 0.0159	+0.0189 [+0.0107, +0.0278]	0.0039	1.30	9/10	Intermedia
FS1_zpd4	+0.0105 ± 0.0150	+0.0200 [+0.0130, +0.0274]	0.00195 (Holm 0.0039)	1.61	10/10	Adoptada
D2_clean5_zpd2	**+0.0203 ± 0.0167**	**+0.0298 [+0.0225, +0.0372]**	**0.00195**	**2.40**	**10/10**	**Seleccionada**
Oráculo ZPD	+0.0411	—	—	—	—	Referencia superior

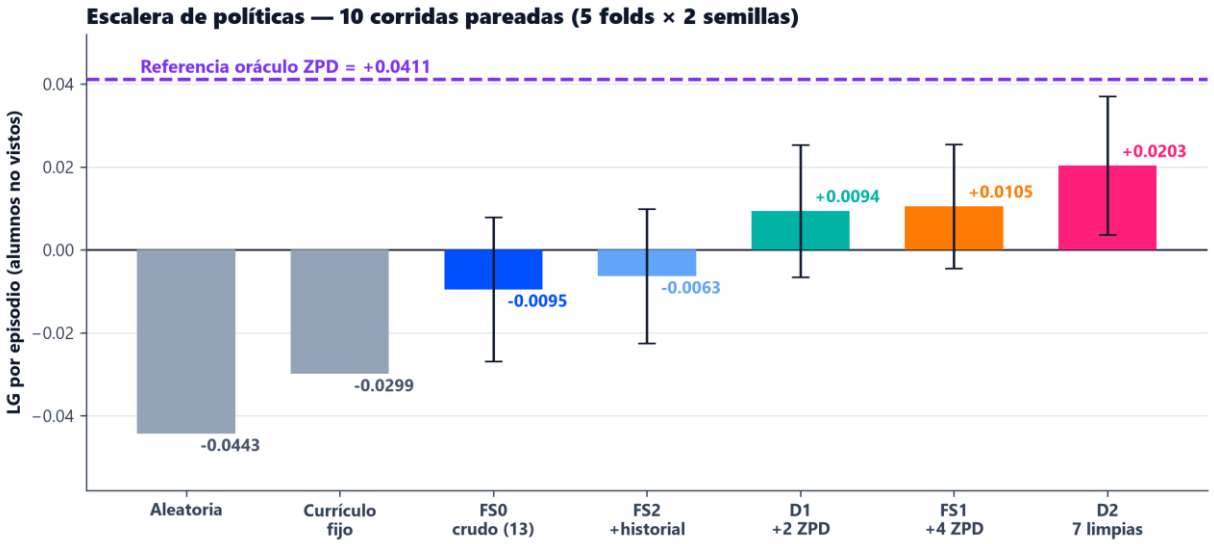


Figura 2. *Ganancia por episodio (media ± 1 DE, 10 corridas). Fuente: summary.json y runs_oracle.json.*

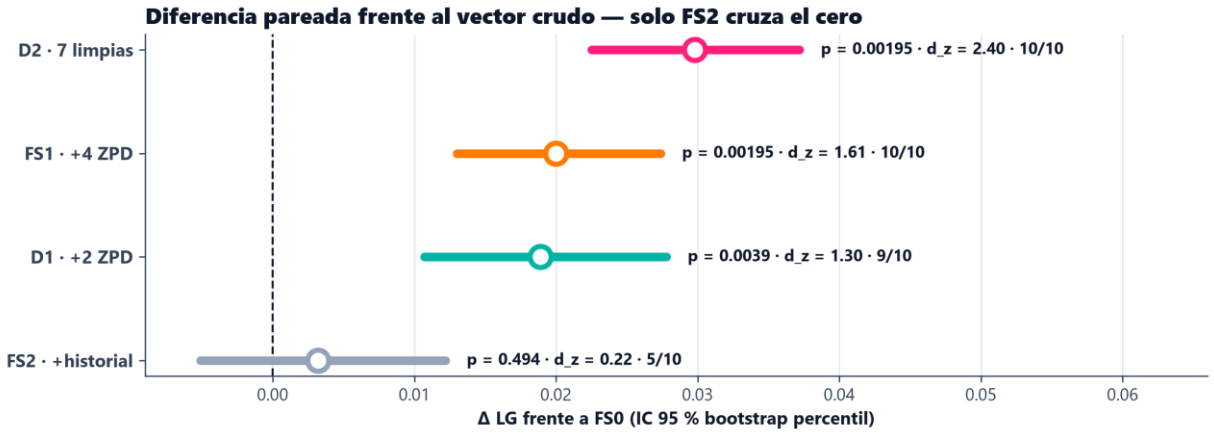


Figura 3. *Diferencia pareada de LG frente a FS0 con IC 95 %. Solo FS2 incluye el cero.*

8.3 Ablaciones

Tabla 9. *Ablaciones controladas.*

Cambio	Resultado	Lectura
Añadir 2 variables ZPD (D1 vs. FS0)	+0.0189, 9/10	El acoplamiento habilidad–dificultad es lo que más mueve la ganancia.
Añadir historial temporal (FS2 vs. FS0)	+0.0032, p = 0.494	Sin efecto detectable; se descarta.
Depurar estado (D2 vs. FS1)	+0.0098 [+0.0012, +0.0204], p = 0.0605, d_z = 0.60, 8/10	Tendencia favorable, no significativa con 10 corridas.

Importancia de variables en el modelo de transición (5 folds): zpd_hit ΔAUC = +0.0959 y abs_gap +0.0140; theta_3 +0.0047 y las otras cuatro ≈ 0 o negativas. Por |SHAP|, zpd_hit es primera (0.0677) y abs_gap cuarta (0.0127). VIF máximo = 2.125 (abs_gap). Fuente: sprint2_diagnostics.json.

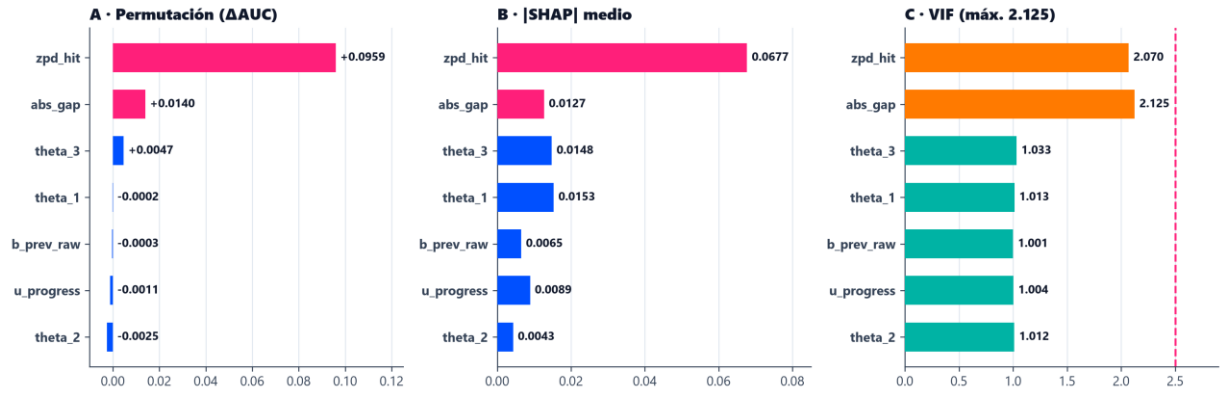


Figura 4. *Importancia por permutación, |SHAP| y VIF del vector de 7 variables.*

8.4 Robustez y casos de fallo

- **Variabilidad entre corridas.** D2 va de −0.0029 a +0.0496; una de las diez corridas es negativa.
- **Habilidad estimada con ruido.** Con un estimador Elo en línea (k = 0.1) la ventaja baja a +0.0095 (4/5 folds, p = 0.25): no concluyente. El resultado principal depende de observar la habilidad verdadera.
- **Costo.** Sobrecosto de latencia de FS1: +0.11 ms por decisión.

8.5 Interpretación y amenazas a la validez

Interpretación. En una sesión corta el olvido domina: las políticas base pierden habilidad neta. Informar al agente de la distancia habilidad–dificultad revierte el signo y recupera cerca de la mitad de lo que logra la heurística con oráculo. La distancia entre esa heurística (+0.0411) y la cota de 0.3255 sugiere que el banco rara vez ofrece textos dentro de la ZPD; es una pregunta abierta para el siguiente sprint.

Tabla 10. *Amenazas a la validez.*

Amenaza	Descripción
Constructo	zpd_hit reproduce la regla con la que el simulador genera aprendizaje; su poder predictivo es esperable por construcción.
Interna	El agente observa θ verdadero; con estimadores reales la ventaja puede reducirse (ver Elo).
Estadística	n = 10 corridas con dependencia entre semillas del mismo fold.
Externa	Estudiantes sintéticos e ítems con parámetros muestreados; nada se generaliza a escolares.

9. Conclusiones y próximos pasos

9.1 Conclusiones sustentadas

01 Las variables de acoplamiento ZPD mejoran la ganancia frente al vector crudo (+0.0200, 10/10 corridas).

02 El vector depurado de 7 variables obtiene la mejor ganancia (+0.0203) y alcanza el 49 % de la referencia de oráculo.

03 El historial temporal no aporta; la depuración adicional muestra una tendencia que aún no es significativa.

No determinado al corte: efecto de Dyna-PPO y del ajuste de hiperparámetros; desempeño con MSKT/NeuralCD; transferencia a otro simulador; efecto en estudiantes reales.

9.2 Riesgos

Tabla 11. *Riesgos y mitigación.*

Riesgo	Impacto	Mitigación
Circularidad variable–simulador	Alto	Evaluar la política congelada en un simulador de otra familia (BKT).
Dependencia de θ verdadero	Alto	Sustituir por estimador aprendido y repetir la comparación.
Brecha entre título y prototipo	Alto	Priorizar Dyna-PPO y un estimador; acordar con la asesora el alcance final.
Potencia estadística	Medio	Evaluación confirmatoria con más corridas y particiones nuevas.

9.3 Siguiente sprint

Tabla 12. *Plan del siguiente sprint.*

Actividad	Entregable	Criterio de aceptación	Semana
Modelo del mundo + Dyna-PPO	Módulos en src/ y logs por corrida	Resultados generados por script versionado	10–11
Búsqueda de hiperparámetros	Registro de trials	Espacio fijado antes de ejecutar	12
Evaluación confirmatoria	Tabla con particiones nuevas	Criterio de HG enmendada	13–14

Referencias

Altman, E. (1999). Constrained Markov decision processes. Chapman & Hall/CRC.

Birnbaum, A. (1968). Some latent trait models and their use in inferring an examinee's ability. En F. M. Lord & M. R. Novick (Eds.), Statistical theories of mental test scores (pp. 397–479). Addison-Wesley.

Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2.ª ed.). Lawrence Erlbaum.

Corbett, A. T., & Anderson, J. R. (1994). Knowledge tracing: Modeling the acquisition of procedural knowledge. User Modeling and User-Adapted Interaction, 4(4), 253–278.

Csikszentmihalyi, M. (1990). Flow: The psychology of optimal experience. Harper & Row.

Doroudi, S., Aleven, V., & Brunskill, E. (2019). Where's the reward? A review of reinforcement learning for instructional sequencing. International Journal of Artificial Intelligence in Education, 29(4), 568–620.

García, J., & Fernández, F. (2015). A comprehensive survey on safe reinforcement learning. Journal of Machine Learning Research, 16(42), 1437–1480.

Hake, R. R. (1998). Interactive-engagement versus traditional methods. American Journal of Physics, 66(1), 64–74.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65–70.

Janner, M., Fu, J., Zhang, M., & Levine, S. (2019). When to trust your model: Model-based policy optimization. NeurIPS 32.

Kintsch, W. (1998). Comprehension: A paradigm for cognition. Cambridge University Press.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. NeurIPS 30.

MINEDU. (2016). Currículo Nacional de la Educación Básica. Ministerio de Educación del Perú.

OECD. (2023). PISA 2022 results (Volume I). OECD Publishing.

Pandey, S., & Karypis, G. (2019). A self-attentive model for knowledge tracing. EDM 2019.

Piech, C., et al. (2015). Deep knowledge tracing. NeurIPS 28.

Schulman, J., Moritz, P., Levine, S., Jordan, M., & Abbeel, P. (2016). High-dimensional continuous control using generalized advantage estimation. ICLR 2016.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. arXiv:1707.06347.

Shin, D., et al. (2021). SAINT+: Integrating temporal features for EdNet correctness prediction. LAK21.

Sutton, R. S. (1991). Dyna, an integrated architecture for learning, planning, and reacting. ACM SIGART Bulletin, 2(4), 160–163.

Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction (2.ª ed.). MIT Press.

Vygotsky, L. S. (1978). Mind in society. Harvard University Press.

Wang, F., et al. (2020). Neural cognitive diagnosis for intelligent education systems. AAAI 34(04), 6153–6161.

MATERIAL DE SOPORTE

Anexos

Anexo A. Matriz de consistencia

Tabla 13. *Matriz de consistencia.*

Problema	Objetivo	Hipótesis	Variables	Indicador y resultado
PG	OG	HG: PPO con vector depurado supera a vector crudo y políticas base	VI: conjunto de variables y política. VD: ganancia	LG −0.0095 → +0.0203; Δ = +0.0298 [+0.0225, +0.0372]; 49 % del oráculo
PE1	OE1	HE1: zpd_hit y abs_gap son las más informativas	VI: zpd_hit, abs_gap. VD: transición de aprendizaje	ΔAUC #1 y #2; |SHAP| #1 y #4. Parcial
PE2	OE2	HE2: depurar el estado mejora la ganancia	VI: estado limpio vs. completo. VD: ganancia	Δ = +0.0098, p = 0.0605. No confirmada
PE3	OE3	HE3: Dyna-PPO ajustado supera a PPO	VI: planificación e hiperparámetros. VD: ganancia y eficiencia	Sin evaluar (Semanas 10–14)

Anexo B. Enlace al último branch y trazabilidad

Rama de entrega:

https://github.com/yasminum/SistemaTutorInteligente/tree/feat/hyperparameter-optimization — código, datos, logs y resultados reales verificados en commit 77c6cfe (compilación final de este informe añadida en docs/). La rama conserva su nombre original aunque la búsqueda de hiperparámetros quedó planificada para la Semana 12.

Tabla 14. *Ramas y commits del sprint.*

Etapa	Rama	Commit
EDA (Semana 4)	eda	723cbf8
Variables ZPD (Semana 5)	feature-engineering	b1dd663
Auditoría y poda (Semana 6)	data-centric-audit-and-pruning	b8795ab
Importancia y matriz (Semana 7)	feat/variable-importance-and-consistency-matrix	e659281
Saneamiento código/datos (Semana 9)	feat/hyperparameter-optimization	77c6cfe

Anexo C. Variables

Tabla 15. *Diccionario y decisión por variable.*

Variable	Definición	Decisión
zpd_hit	1[|θ_k − b| < 0.5]	Retenida

Variable	Definición	Decisión
abs_gap	|θ_k − b|	Retenida
theta_1, theta_2, theta_3	Habilidad por competencia	Retenidas
b_prev_raw, u_progress	Dificultad previa y avance t/50	Retenidas (sin ablación propia)
zpd_prox, signed_gap	Proximidad gaussiana y brecha con signo	Descartadas por colinealidad
sigma_1..3, u_acc, u_streak, tau_1, tau_2, E_hat	Columnas sin variación	Descartadas

Anexo D. Registro de corridas

Configuración (runs_oracle.json): n_students = 100, k_folds = 5, fold_seed = 2026, bank_seed = 2026, seeds = [0, 1], train_episodes = 1500. code_sha256 = ed9d8eac…49b1a · data_sha256 = 07ed76f0…d4706.

Tabla 16. *LG por corrida de D2_clean5_zpd2.*

Fold-semilla	1	2	3	4	5	6	7	8	9	10
D2 LG	−0.0029	0.0085	0.0100	0.0044	0.0382	0.0345	0.0496	0.0152	0.0269	0.0185

Anexo E. Pruebas de no-fuga

Tabla 17. *Pruebas de no-fuga (python -m src.leakage_checks y tests/test_leakage_checks.py). Resultado: 5/5 PASS (leakage_all_pass = true).*

Prueba	Qué verifica
L1	Ningún estudiante aparece en entrenamiento y validación del mismo fold
L2	El estado en t no cambia al alterar respuestas futuras
L3	Las variables ZPD usan solo información previa a la acción
L4	Las transformaciones se ajustan solo en entrenamiento
L5	Política congelada en evaluación (pesos idénticos antes y después de evaluar en test)