UNIVERSIDAD NACIONAL DE INGENIERÍA

Unidad de Posgrado · Facultad de Ingeniería Industrial y de Sistemas

INFORME PARCIAL

Proyecto de Investigación II · Plan de tesis y protocolo experimental

Sistema de Tutoría Inteligente Adaptativa para Comprensión Lectora mediante Deep Reinforcement Learning Integrado con MSKT y NeuralCD: Un Enfoque Basado en Literatura Peruana

Tipo de tesis: Académica (Maestría en Inteligencia Artificial)

GRUPO 2	**Flores Rivera, Amit Roy** · **Urrego Montoya, Yasmin**
ASESORA	Mg. Ing. María Fernanda Tejada Begazo
DOCENTE DEL CURSO	Dr. Glen Dario Rodríguez Rafael
CORTE	Semana 9 · Lima, 13 de noviembre de 2026
REPOSITORIO	`https://github.com/yasminum/SistemaTutorInteligente` (rama `feat/hyperparameter-optimization`, commit `77c6cfe`)

Resumen ejecutivo

El plan de tesis propone un tutor adaptativo de comprensión lectora que decide qué texto asignar mediante aprendizaje por refuerzo. La arquitectura objetivo combina seguimiento de conocimiento multiescala (MSKT), diagnóstico cognitivo neuronal (NeuralCD) y planificación basada en modelo (*Dyna-PPO*). **Al corte de la Semana 9 está ejecutado y versionado un prototipo más acotado:** un simulador IRT-3PL con zona de desarrollo próximo (ZPD) y olvido, un agente PPO lineal (`src/agent_ppo_linear.py`) y un estudio de ingeniería de variables con validación cruzada agrupada por estudiante ($k = 5$ *folds* $\times$ 2 semillas $= 10$ corridas pareadas).

$-0.0095 \rightarrow +0.0203$
Ganancia LG por episodio:
vector crudo (`FS0`)
$\rightarrow$ depurado (`D2`)

$+0.0298$
Diferencia pareada ΔLG
IC 95 % $[+0.0225, +0.0372]$
$\cdot$ $10/10$ corridas

49.4 **%**
de la heurística con oráculo
$(\mathrm{LG}_{\text{oráculo}} = +0.0411)$

Alcance y componentes pendientes
Dyna-PPO, la búsqueda sistemática de hiperparámetros y los estimadores aprendidos MSKT y NeuralCD **no están ejecutados** al corte de la Semana 9 y se planifican para las Semanas 10–16. Todas las conclusiones de desempeño se restringen estrictamente a estudiantes sintéticos en simulación *in-silico*.

Índice general

PARTE I. Plan de tesis 3
Datos generales . . . 3

Capítulo I. Planteamiento del problema 3
1.1. Diagnóstico . . . 3
1.2. Justificación y alcances . . . 4

Capítulo II. Objetivos 4

Capítulo III. Marco teórico 5
3.1. Bases teóricas . . . 5
3.2. Definición de términos . . . 6
3.3. Hipótesis y variables . . . 6

Capítulo IV. Diseño metodológico 7

Capítulo V. Administración del plan 8
5.1. Cronograma . . . 8
5.2. Presupuesto y financiamiento . . . 8

PARTE II. Protocolo y avance experimental 9

6. Datos y material de estudio 9

7. Protocolo experimental 9

8. Resultados parciales y evidencia 10
8.1. Estado de implementación . . . 10
8.2. Comparación cuantitativa . . . 10
8.3. Ablaciones e importancia de variables . . . 11
8.4. Robustez y casos de fallo . . . 12
8.5. Interpretación y amenazas a la validez . . . 12

9. Conclusiones y próximos pasos 12
9.1. Conclusiones sustentadas . . . 12
9.2. Riesgos y mitigación . . . 13
9.3. Plan del siguiente sprint (Semanas 10–14) . . . 13

Referencias 14

Anexos 15
Anexo A. Matriz de consistencia . . . 15
Anexo B. Enlace al último branch y trazabilidad . . . 15
Anexo C. Diccionario y decisión por variable . . . 16
Anexo D. Registro individual de corridas . . . 16
Anexo E. Pruebas de no-fuga de datos . . . 16

CAPÍTULOS I A V

PARTE I. Plan de tesis

Datos generales

Tabla 1: Datos generales del plan de tesis.

Campo	Información
Título	Sistema de Tutoría Inteligente Adaptativa para Comprensión Lectora mediante Deep Reinforcement Learning Integrado con MSKT y NeuralCD: Un Enfoque Basado en Literatura Peruana
Autores (Grupo 2)	Flores Rivera, Amit Roy · Urrego Montoya, Yasmin
Asesora	Mg. Ing. María Fernanda Tejada Begazo
Docente del curso	Dr. Glen Dario Rodríguez Rafael
Programa	Maestría en Inteligencia Artificial, Unidad de Posgrado FIIS–UNI
Infraestructura	Equipos personales (CPU) y repositorio GitHub `yasminum/SistemaTutorInteligente`. Estudio *in-silico*.
Duración y corte	16 semanas académicas; corte de este informe: Semana 9 (13/11/2026).

Capítulo I. Planteamiento del problema

1.1 Diagnóstico

En PISA 2022, únicamente el 50 % de los estudiantes peruanos de 15 años alcanzó al menos el Nivel 2 de lectura, frente al 74 % del promedio OCDE (OECD, 2023). Las brechas se concentran en las capacidades inferencial y crítica definidas en el Currículo Nacional de la Educación Básica (MINEDU, 2016).

- **Síntoma:** el estudiante recibe textos demasiado fáciles o demasiado difíciles para su nivel actual, provocando el estancamiento del aprendizaje.
- **Causa técnica:** los tutores de secuencia fija no adaptan la dificultad al estado del estudiante, mientras que las políticas que optimizan únicamente el acierto inmediato tienden a asignar material fácil (Doroudi et al., 2019).
- **Consecuencia:** se carece de una política de secuenciación validada cuantitativamente en simulación antes de cualquier intervención con escolares.

Problema de estudio

Diseñar y evaluar en simulación una política que elija, en cada uno de los $T = 50$ pasos de una sesión, el par texto–nivel cuya dificultad ajustada b_{adj} mejor se acople a la habilidad θ_k del estudiante en $K = 3$ competencias lectoras (literal, inferencial y crítica).

Antecedentes

- **Seguimiento de conocimiento:** BKT (Corbett & Anderson, 1994), DKT (Piech et al., 2015), SAKT (Pandey & Karypis, 2019) y SAINT+ (Shin et al., 2021) predicen la probabilidad de acierto futuro, pero no prescriben qué ítem o texto asignar. MSKT es el estimador de conocimiento previsto en la arquitectura objetivo (planificado para Semanas 13–14).
- **Diagnóstico cognitivo:** NeuralCD (Wang et al., 2020) estima un perfil de dominio interpretable por competencia mediante interacción neuronal monótona.
- **Secuenciación con RL:** Doroudi et al. (2019) revisan el uso de RL para secuenciación instruccional y

reportan resultados sensibles al modelo del estudiante. PPO (Schulman et al., 2017) constituye el algoritmo base implementado; Dyna (Sutton, 1991) y MBPO (Janner et al., 2019) fundamentan la planificación con modelo prevista.

Formulación del problema

- **Problema general (PG):** ¿En qué medida una política de aprendizaje por refuerzo, alimentada con variables depuradas de acoplamiento habilidad–dificultad, mejora la ganancia de aprendizaje simulada LG frente a políticas base en un entorno IRT-3PL?
- **PE1:** ¿Cuánto aportan las variables de acoplamiento (`zpd_hit`, `abs_gap`) a predecir la transición de aprendizaje y a elevar la ganancia de la política?
- **PE2:** ¿Mejora la ganancia LG al eliminar columnas sin información y variables colineales del vector de estado?
- **PE3:** ¿Mejora la ganancia y la eficiencia muestral al incorporar planificación con modelo (*Dyna-PPO*) y ajuste sistemático de hiperparámetros? **(Planificado; sin evidencia al corte.)**

1.2 Justificación y alcances

- **Justificación:** *Metodológica:* establece un protocolo reproducible de selección de variables con partición agrupada por estudiante y pruebas automatizadas de no-fuga. *Práctica:* entrega una base de software verificable antes de exponer a estudiantes reales. *Social:* orienta el diseño curricular al 3.er grado de secundaria en el Perú.
- **Alcances:** (a) Estudio estrictamente *in-silico*; ninguna conclusión se extiende a escolares reales. (b) El banco actual es paramétrico: 30 textos $\times$ 10 ítems $=$ 300 ítems con parámetros IRT muestreados (`bank_seed = 2026`); su vinculación con textos de literatura peruana es trabajo planificado. (c) En el prototipo actual el agente observa la habilidad verdadera θ del simulador; sustituirla por estimadores aprendidos (MSKT, NeuralCD) es trabajo planificado.

Capítulo II. Objetivos

Objetivo general (OG): Desarrollar y evaluar en simulación una política de secuenciación adaptativa de textos basada en aprendizaje por refuerzo que maximice la ganancia de aprendizaje LG en comprensión lectora.

Tabla 2: Objetivos específicos y estado de avance al corte de la Semana 9.

Objetivo	Descripción	Estado al corte
OE1	Determinar el aporte de las variables de acoplamiento ZPD (`zpd_hit`, `abs_gap`).	Ejecutado
OE2	Evaluar el efecto de depurar el estado (eliminación de columnas muertas y colineales).	Ejecutado; no concluyente
OE3	Evaluar *Dyna-PPO*, búsqueda de hiperparámetros y estimadores MSKT/NeuralCD.	Planificado (Sem. 10–16)

Capítulo III. Marco teórico

3.1 Bases teóricas

Siguiendo a Kintsch (1998) y al Currículo Nacional, se modelan $K = 3$ competencias lectoras (literal, inferencial y crítica). En cada paso $t \in \{1, \dots, 50\}$, la probabilidad de acierto de un estudiante con habilidad $\theta_k \in [0, 1]$ sobre un ítem con discriminación a_j, dificultad ajustada $b_{\text{adj},j}$ y parámetro de azar c sigue el modelo logístico IRT-3PL (Birnbaum, 1968):

$$P(Y_{t,j} = 1 \mid \theta_k, a_j, b_{\text{adj},j}, c) = c + \frac{1 - c}{1 + \exp\big(-1.7\, a_j(\theta_k - b_{\text{adj},j})\big)}, \tag{1}$$

donde $a_j \sim \mathcal{U}(0.8,\, 2.0)$, $b_j \sim \mathcal{N}(0,\, 1)$, $c = 0.25$ y $b_{\text{adj},j} = b_j + (\text{nivel} - 1) \cdot 0.5$ para nivel $\in \{0, 1, 2\}$. La ejecución de la respuesta modula P por fatiga según $P_{\text{ef}} = P \cdot (1 - 0.1\,\text{fatiga})$.

Zona de desarrollo próximo (ZPD) y olvido

El simulador (`src/simulator.py`) incrementa la habilidad solo cuando el acierto ocurre dentro de la ventana de zona de desarrollo próximo (Vygotsky, 1978; Csikszentmihalyi, 1990) $|\theta_k - b_{\text{adj},j}| < 0.5$, seguido de un decaimiento multiplicativo por olvido en cada paso:

$$\theta_k^{+} = \theta_k + u\,(1 - \theta_k) \cdot \mathbf{1}\big[|\theta_k - b_{\text{adj},j}| < 0.5 \;\wedge\; Y_{t,j} = 1\big], \qquad u \sim \mathcal{U}(0.02,\, 0.05), \tag{2}$$

$$\theta_m^{\text{next}} = \text{clip}\Big(\theta_m^{+} \cdot (1 - \delta_m),\; 0,\; 1\Big), \qquad \delta_m \sim \mathcal{U}(0.001,\, 0.005), \quad m \in \{1, 2, 3\}. \tag{3}$$

Política PPO lineal y recompensa escalar

El prototipo (`src/agent_ppo_linear.py`) implementa optimización de política proximal (PPO; Schulman et al., 2017) con política softmax lineal sobre las 90 acciones (30 textos $\times$ 3 niveles) y estimación de ventaja generalizada GAE(γ, λ) (Schulman et al., 2016):

$$L^{\text{CLIP}}(\phi) = \hat{\mathbb{E}}_t\Big[\min\Big(r_t(\phi)\hat{A}_t,\; \text{clip}\big(r_t(\phi),\, 1 - \epsilon,\, 1 + \epsilon\big)\hat{A}_t\Big)\Big], \qquad r_t(\phi) = \frac{\pi_\phi(a_t \mid s_t)}{\pi_{\phi_{\text{old}}}(a_t \mid s_t)}, \quad \epsilon = 0.2, \tag{4}$$

con $\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}^{V}$ ($\gamma = 0.99$, $\lambda = 0.95$), penalización de entropía 0.01, $lr_\pi = 0.02$ y $lr_V = 0.01$. La recompensa escalar replica $R_t = \text{clip}(0.5\,\Delta KS + 0.25\,\hat{E} + 0.25\,\hat{F} - 0.5\,\text{costo},\, -1,\, 1)$, donde $\Delta KS = 0.01\,Y_t$ y $\hat{E} = 0.7 + 0.3\,Y_t$ premian el acierto inmediato, $\hat{F}$ mide proximidad gaussiana a ZPD y costo penaliza repetir ítem o saltos $|\Delta\text{nivel}| > 1$; además, un escudo fuerza nivel $= 0$ cuando la racha de errores ≥ 4.

Planificación con modelo y seguridad (arquitectura objetivo)

Dyna (Sutton, 1991; Sutton & Barto, 2018) con *rollouts* cortos (Janner et al., 2019) y restricciones CMDP (Altman, 1999; García & Fernández, 2015) forman parte de la arquitectura objetivo aún no implementada (Semanas 10–14).

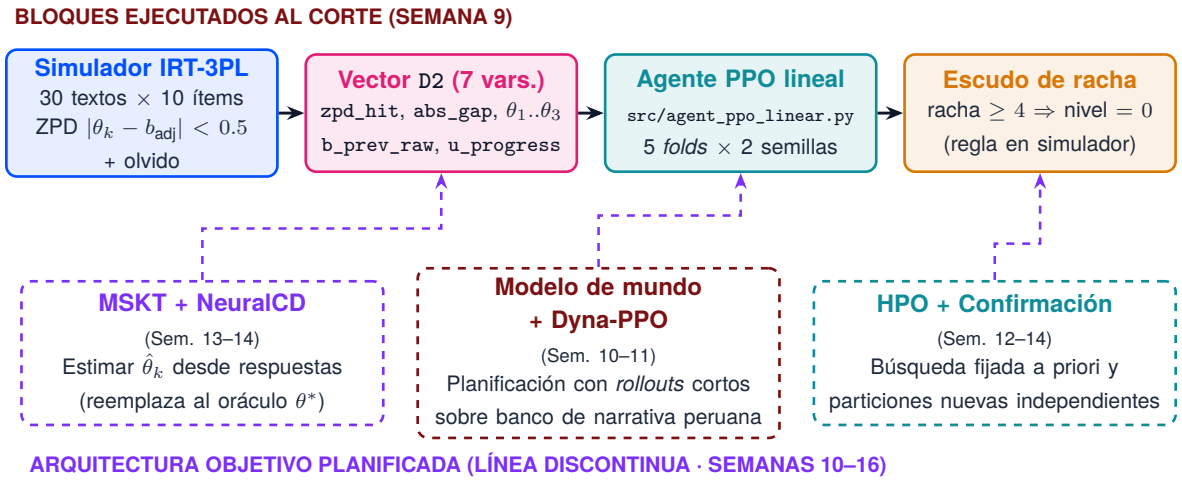


Figura 1: Arquitectura del sistema: bloques implementados y ejecutados (arriba, trazo continuo) frente a componentes planificados (abajo, trazo discontinuo). La figura no contiene cifras de resultados.

3.2 Definición de términos

- **Ganancia normalizada de Hake (LG; Hake, 1998):** medida sobre la habilidad verdadera promedio $\bar{\theta} = \frac{1}{3}\sum_{k=1}^{3}\theta_k$ al inicio y término de los $T = 50$ pasos en alumnos no vistos:

$$\mathrm{LG} = \frac{\bar{\theta}_{\text{post}} - \bar{\theta}_{\text{pre}}}{1 - \bar{\theta}_{\text{pre}}}. \tag{5}$$

- **Variables de acoplamiento ZPD:** $\mathrm{zpd_hit} = \mathbf{1}\big[|\theta_k - b_{adj}| < 0.5\big]$ y $\mathrm{abs_gap} = |\theta_k - b_{adj}|$ evaluadas antes de ejecutar la acción candidata.
- **Referencia de oráculo ZPD:** heurística que conoce θ^* verdadero del simulador y selecciona la acción que maximiza el indicador esperado de ZPD ($\mathrm{LG} = +0.0411$).

3.3 Hipótesis y variables

Enmienda al protocolo
El umbral original $\mathrm{LG} \geq 0.50$ se retira formalmente: el propio simulador acota la ganancia máxima con acierto dentro de la ZPD en los 50 pasos en $\mathrm{LG}_{\text{máx}} = 0.3255$, y la heurística con oráculo θ^* obtiene $+0.0411$ (`summary.json`). Las hipótesis se reformulan en términos de diferencias pareadas $\Delta\mathrm{LG}$ y de fracción respecto del oráculo.

Tabla 3: Hipótesis de investigación y estado de contrastación al corte.

Hipótesis	Enunciado	Estado al corte
HG	PPO con el vector depurado de 7 variables (D2) supera a PPO con el vector crudo (FS0) y a las políticas aleatoria y de currículo fijo.	Respaldada de forma exploratoria ($+0.0298$, $10/10$ corridas). Criterio confirmatorio propuesto (a fijar con la asesora): particiones y semillas nuevas, IC 95 % sin incluir 0 y ≥ 40 % del oráculo.
HE1	`zpd_hit` y `abs_gap` son las dos variables más informativas del vector de estado–acción.	Parcialmente confirmada (ΔAUC posiciones 1 y 2; $\lvert$SHAP$\rvert$ posiciones 1 y 4).
HE2	Depurar el estado mejora la ganancia frente al vector completo con 4 variables ZPD (FS1).	No confirmada a $\alpha = 0.05$ ($p = 0.0605$, $d_z = 0.60$, $8/10$ corridas).
HE3	*Dyna-PPO* con hiperparámetros ajustados supera a PPO sin modelo.	No evaluada (planificada para Semanas 10–14).

- **Variables independientes:** conjunto de variables de estado–acción (`FS0`, `FS2`, `D1`, `FS1`, `D2`) y tipo de política.
- **Variable dependiente:** ganancia de aprendizaje simulada LG.
- **Indicadores:** LG por episodio, diferencia pareada $\Delta\mathrm{LG}$ con IC 95 %, p_{perm}, d_z, $\Delta\mathrm{AUC}$ por permutación, $|\mathrm{SHAP}|$ medio y VIF.

Capítulo IV. Diseño metodológico

Tabla 4: Resumen del diseño metodológico (Semanas 4–9).

Aspecto	Decisión metodológica
4.1 Tipo	Investigación aplicada, cuantitativa, experimental computacional (*in-silico*).
4.2 Nivel	Explicativo dentro del simulador: se manipula el vector de variables manteniendo constantes los estudiantes, particiones y semillas.
4.3 Método	Sprints semanales versionados en GitHub: EDA, ingeniería de variables, auditoría de datos, importancia de variables.
4.4 Población y muestra	100 estudiantes sintéticos; validación cruzada agrupada (`GroupKFold`, $k = 5$ *folds*: 80 entrenamiento / 20 validación sin traslape de identidad).
4.5 Diseño	Pareado: cada variante se entrena y evalúa sobre las mismas 10 corridas (5 folds $\times$ 2 semillas).
4.6 Instrumentos	Simulador (`src/simulator.py`), agente (`src/agent_ppo_linear.py`), corredor experimental (`src/experiment.py`) y registros JSON/CSV en `data/results/`.
4.7 Análisis estadístico	Diferencia pareada $\bar{d}$ con IC 95 % bootstrap percentil ($B = 10\,000$), prueba exacta de permutación de signos, corrección de Holm (1979), tamaño del efecto $d_z = \bar{d}/s_d$ (Cohen, 1988), $\Delta\mathrm{AUC}$ por permutación, $\|\mathrm{SHAP}\|$ (Lundberg & Lee, 2017) y VIF.
4.8 Etapas	Cuatro ejecutadas (Semanas 4–7); Semanas 8–9 dedicadas a depurar la evidencia y a este informe; cierre en Semanas 10–16.

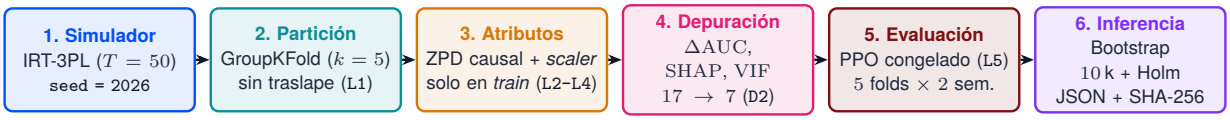


Figura 2: Flujo metodológico reproducible y controles automáticos de no-fuga (`L1`–`L5`) ejecutados al corte.

Capítulo V. Administración del plan

5.1 Cronograma

Tabla 5: Cronograma de 16 semanas.

Semanas	Actividad	Producto verificable	Estado
1–3	Simulador IRT-3PL y banco paramétrico	`src/simulator.py`	**Hecho**
4	Análisis exploratorio (EDA)	Rama `eda` (`723cbf8`)	**Hecho**
5	Variables ZPD y pruebas de no-fuga	Rama `feature-engineering`	**Hecho**
6–7	Auditoría, importancia y matriz de consistencia	`summary.json`, `runs_oracle.json`	**Hecho**
8–9	Depuración de evidencia e informe parcial	Este informe (LaTeX/PDF)	**Hecho**
10–11	Modelo del mundo, *Dyna-PPO* y ablación real	Código y logs por corrida	Planificado
12	Búsqueda sistemática de hiperparámetros	Registro de trials por script	Planificado
13–14	Estimador de habilidad aprendido y evaluación confirmatoria	Tabla confirmatoria	Planificado
15–16	Redacción final y sustentación	Informe final y *release*	Planificado

5.2 Presupuesto y financiamiento

Sin desembolso monetario directo: se emplea software libre (Python, NumPy, scikit-learn, LaTeX) y equipos personales de cómputo. El aporte es íntegramente en especie (horas de investigación de los dos autores y tiempo de CPU). Proyecto autofinanciado.

SECCIONES 6 A 9

PARTE II. Protocolo y avance experimental

6. Datos y material de estudio

- **6.1 Origen:** datos 100 % sintéticos generados determinísticamente por el simulador. Código, artefactos y registros versionados en GitHub (véase Anexo B).
- **6.2 Estructura y EDA:** 100 estudiantes $\times 50$ pasos por sesión. Al vector crudo de 13 variables se añadieron 4 variables de acoplamiento ZPD. La auditoría centrada en datos (`sprint2_diagnostics.json`) detectó 8 columnas sin variación informativa (`n_dead_xt` $= 8$): cinco marcadores constantes (`u_acc`, `u_streak`, `tau_1`, `tau_2`, `E_hat`) y tres de incertidumbre (`sigma_1..3`) constantes. Asimismo, `zpd_prox` y `signed_gap` exhiben alta colinealidad con `zpd_hit` ($r = 0.850$) y `abs_gap`.
- **6.3 Ética:** no existen datos personales ni interacción con menores. Toda prueba futura con escolares requerirá aprobación de comité de ética y consentimiento informado.
- **6.4 Control de fugas:** partición agrupada por `student_id`, características ZPD construidas exclusivamente con información previa a la acción y escaladores ajustados únicamente sobre el subconjunto de entrenamiento. Verificación automática: `leakage_all_pass` $=$ `true` ($5/5$ pruebas).

7. Protocolo experimental

- **7.1 Preguntas experimentales: E1:** ¿Las variables ZPD incrementan LG frente al vector crudo? **E2:** ¿Aporta el historial temporal? **E3:** ¿Mejora la ganancia al depurar variables muertas y colineales? **E4:** ¿Cómo responde la ventaja cuando θ se estima con ruido (Elo en línea)?
- **7.2 Particiones:** `GroupKFold` con $k = 5$ *folds* por estudiante (`fold_seed` $= 2026$) y 2 semillas de entrenamiento ($\{0, 1\}$) por *fold*.
- **7.3 Métricas y estadística:** métrica primaria LG (ec. 5) en alumnos de validación. Comparación pareada frente a `FS0_raw13`: diferencia media $\bar{d}$ con IC 95 % bootstrap percentil ($B = 10\,000$), prueba exacta de permutación de signos (mínimo alcanzable $\frac{2}{2^{10}} = \frac{2}{1024} \approx 0.00195$), corrección de Holm y $d_z = \bar{d}/s_d$. **Limitación declarada y protocolo confirmatorio:** las dos semillas dentro de un mismo *fold* comparten los mismos 20 estudiantes de validación, por lo que las 10 corridas constituyen 5 bloques independientes y los p-valores son aproximados. En la fase confirmatoria (Sem. 13–14), las semillas se promediarán por *fold* o por alumno sobre una partición virgen ($N \geq 100$ nuevos) nunca usada en la selección de `D2`.

Tabla 6: Políticas de referencia y variantes evaluadas (Sección 7.4).

Identificador	Descripción
Aleatoria / Currículo fijo	Políticas de referencia sin aprendizaje (selección uniforme; secuencia fija de textos en nivel medio).
`FS0_raw13`	PPO lineal con las 13 variables crudas del estado (línea base).
`FS2_hist6`	`FS0` + 6 variables de historial temporal.
`D1_zpd2`	`FS0` + `zpd_hit` y `abs_gap`.
`FS1_zpd4`	`FS0` + 4 variables de acoplamiento ZPD.
`D2_clean5_zpd2`	5 variables de estado limpias (`theta_1..3`, `b_prev_raw`, `u_progress`) + `zpd_hit` y `abs_gap` (7 variables).
Oráculo ZPD	Heurística con θ^* verdadero que maximiza `zpd_hit` (referencia superior).

- **7.5 Ingeniería de atributos:** reducción de 17 variables candidatas a 7 retenidas (descarte de 8 columnas

muertas y 2 colineales).

- **7.6 Hiperparámetros:** configuración fija sin búsqueda: 1 500 episodios de entrenamiento, $lr_\pi = 0.02$, $lr_V = 0.01$, $\epsilon_{\text{clip}} = 0.2$, coeficiente de entropía 0.01, $\gamma = 0.99$, $\lambda = 0.95$. La búsqueda sistemática queda planificada para la Semana 12.
- **7.7 Reproducibilidad:** semillas, hiperparámetros y huellas SHA-256 de código y datos almacenadas en `runs_oracle.json`; pruebas unitarias en `tests/test_leakage_checks.py`.

8. Resultados parciales y evidencia

8.1 Estado de implementación

Depuración de evidencia respecto del avance de la Semana 8
Las cifras de ablación B0–B5 y de optimización de hiperparámetros reportadas en el borrador previo (LG entre 0.50 y 0.53) no provenían de corridas ejecutadas sobre el código versionado. Fueron retiradas junto con sus figuras, tanto del informe como de la rama de entrega.

Tabla 7: Estado de implementación de componentes al corte de la Semana 9.

Componente del sistema	Estado
Simulador IRT-3PL con ventana ZPD y olvido multiplicativo	**Ejecutado**
Variables ZPD, auditoría de columnas e importancia (ΔAUC, $\lvert$SHAP$\rvert$, VIF)	**Ejecutado**
Agente PPO lineal evaluado en 10 corridas pareadas (`oracle`) y 5 *folds* (`elo`)	**Ejecutado**
Modelo del mundo y planificación *Dyna-PPO*	**Planificado**
Búsqueda sistemática de hiperparámetros (HPO)	**Planificado**
Estimadores cognitivos aprendidos MSKT y NeuralCD	**Planificado**

8.2 Comparación cuantitativa

Tabla 8: Desempeño en alumnos no vistos (10 corridas pareadas: 5 *folds* × 2 semillas). Fuente: `summary.json` y `runs_oracle.json`.

Política / vector	LG (media ± DE)	ΔLG vs. FS0 [IC 95 %]	p_{perm}	d_z	Vict.	Decisión
Aleatoria	-0.0443	—	—	—	—	Referencia
Currículo fijo	-0.0299	—	—	—	—	Referencia
`FS0_raw13`	-0.0095 ± 0.0174	—	—	—	—	Línea base
`FS2_hist6`	-0.0063 ± 0.0162	$+0.0032$ $[-0.0051, +0.0122]$	0.494	0.22	$5/10$	Descartada
`D1_zpd2`	$+0.0094 \pm 0.0159$	$+0.0189$ $[+0.0107, +0.0278]$	0.0039	1.30	$9/10$	Intermedia
`FS1_zpd4`	$+0.0105 \pm 0.0150$	$+0.0200$ $[+0.0130, +0.0274]$	0.00195 (Holm 0.0039)	1.61	$10/10$	Adoptada
`D2_clean5_zpd2`	$+0.0203 \pm 0.0167$	$+0.0298$ $[+0.0225, +0.0372]$	0.00195	2.40	$10/10$	**Seleccionada**
Oráculo ZPD	$+0.0411$	—	—	—	—	Ref. superior

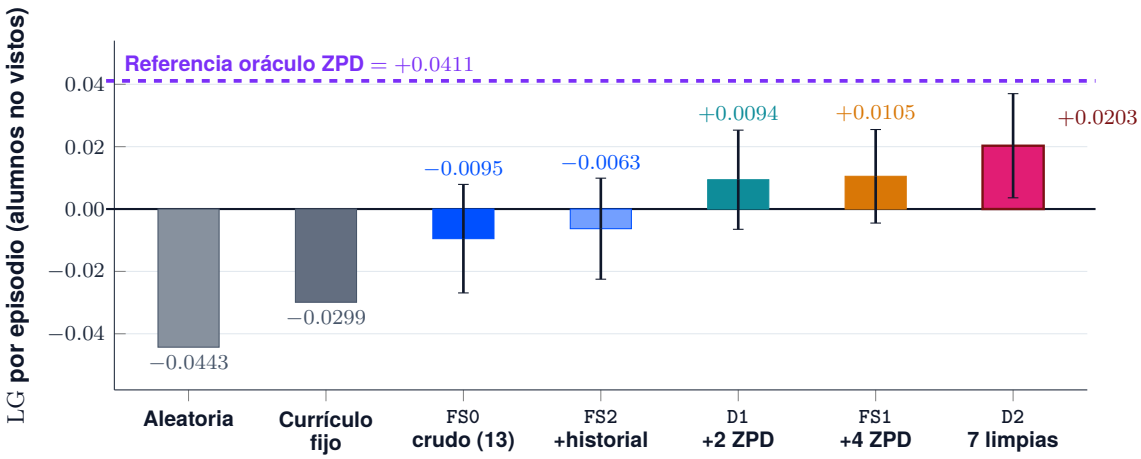


Figura 3: Escalera de políticas: ganancia LG por episodio (media ± 1 DE sobre 10 corridas pareadas). Fuente: `summary.json` y `runs_oracle.json`.

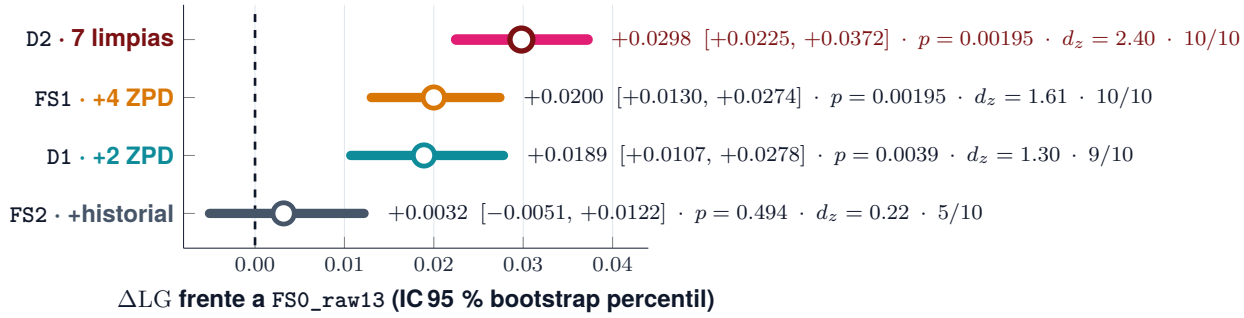


Figura 4: Diferencia pareada ΔLG respecto al vector crudo `FS0_raw13`. Solo el historial temporal (`FS2`) cruza el cero.

8.3 Ablaciones e importancia de variables

Tabla 9: Ablaciones controladas sobre el vector de estado–acción.

Cambio evaluado	Resultado pareado	Lectura técnica
Añadir 2 vars. ZPD (`D1` vs. `FS0`)	$+0.0189$ $[+0.0107, +0.0278]$, $9/10$	El acoplamiento habilidad–dificultad explica el salto principal de LG.
Añadir historial (`FS2` vs. `FS0`)	$+0.0032$, $p = 0.494$, $5/10$	Sin efecto detectable; variante descartada.
Depurar estado (`D2` vs. `FS1`)	$+0.0098$ $[+0.0012, +0.0204]$, $p = 0.0605$, $d_z = 0.60$, $8/10$	Tendencia favorable consistente, aún no significativa a $\alpha = 0.05$ con 10 corridas.

En el modelo supervisado de transición de aprendizaje (`sprint2_diagnostics.json`, $k = 5$, ROC-AUC $= 0.9479 \pm 0.0049$, Brier $= 0.0703$, ECE $= 0.0576$ frente a AUC $= 0.4974 \pm 0.0178$ en `FS0_raw13`; distinto del contraste base en `summary.json` con `auc_raw` $= 0.9253$ y `auc_sigmoid` $= 0.6395$), `zpd_hit` concentra la importancia por permutación (ΔAUC $= +0.0959$), seguida de `abs_gap` ($+0.0140$) y `theta_3` ($+0.0047$); las cuatro restantes oscilan cerca de cero o negativas. Por magnitud media de Shapley ($|$SHAP$|$), `zpd_hit` lidera (0.0677) y `abs_gap` se ubica cuarta (0.0127). La multicolinealidad del vector depurado de 7 variables permanece controlada con $\mathrm{VIF}_{\max} = 2.125$ (`abs_gap`).

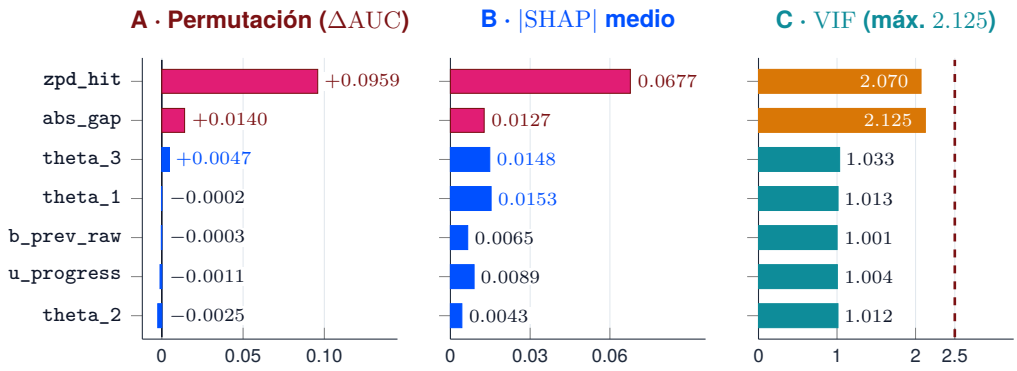


Figura 5: Diagnóstico del vector depurado `D2_clean5_zpd2` (7 variables): importancia por permutación (ΔAUC), contribución media |SHAP| y factor de inflación de varianza VIF (umbral 2.5 en línea discontinua). Fuente: `sprint2_diagnostics.json`.

8.4 Robustez y casos de fallo

- **Variabilidad entre corridas:** las 10 corridas de `D2_clean5_zpd2` abarcan de -0.0029 a $+0.0496$; una corrida (*fold* 0, semilla 0) resulta ligeramente negativa (-0.0029).
- **Habilidad estimada con ruido (Elo en línea, $k = 0.1$):** al reemplazar θ^* verdadero por $\hat{\theta}$ estimado con Elo sobre 5 *folds* (`runs_elo.json`), las medias bajan a `FS0_elo` $= -0.0101 \pm 0.0116$, `FS1_elo` $= -0.0006 \pm 0.0235$ y `D2_elo` $= +0.0009 \pm 0.0203$; la ventaja `FS1` vs. `FS0` cae a $+0.0095$ ($4/5$ *folds*, $p = 0.25$): resultado **no concluyente**. La ventaja principal depende hoy de observar θ^* verdadero.
- **Costo computacional:** el sobrecosto de latencia en inferencia al añadir las variables ZPD en `FS1_zpd4` es $+0.11$ ms por decisión (`summary.json`).

8.5 Interpretación y amenazas a la validez

En una sesión corta de $T = 50$ pasos domina el olvido multiplicativo (ec. 3): tanto las políticas sin aprendizaje como `FS0_raw13` pierden habilidad neta. Informar explícitamente al agente sobre la distancia habilidad–dificultad revierte el signo y recupera el 49.4 % de la ganancia del oráculo ZPD ($+0.0203/+0.0411$). La brecha entre el oráculo ($+0.0411$) y la cota superior de acertar dentro de ZPD en todos los 50 pasos (0.3255) sugiere que el banco paramétrico actual rara vez ofrece ítems dentro de $|\theta_k - b_{\text{adj}}| < 0.5$, hipótesis abierta para el siguiente sprint.

Tabla 10: Amenazas a la validez identificadas al corte.

Tipo de validez	Descripción de la amenaza
Constructo	`zpd_hit` reproduce la regla exacta con la que el simulador genera aprendizaje (ec. 2); su poder predictivo es esperable por construcción.
Interna	El agente observa θ^* verdadero; con estimadores ruidosos de $\hat{\theta}$ la ventaja disminuye (ver prueba Elo).
Estadística	$n = 10$ corridas sobre $k = 5$ *folds* (dependencia intrafold de semillas y selección exploratoria sobre los mismos *folds*); se mitigará en Sem. 13–14 con partición virgen.
Externa	Estudiantes sintéticos e ítems muestreados (`bank_seed=2026`); nada se generaliza a escolares reales.

9. Conclusiones y próximos pasos

9.1 Conclusiones sustentadas

1. **Variables de acoplamiento:** incorporar indicadores de acoplamiento ZPD mejora la ganancia LG frente al vector crudo (`FS1`: $+0.0200$, $p_{\text{perm}} = 0.00195$, $10/10$ corridas; `D1`: $+0.0189$, $9/10$).

2. **Vector depurado:** `D2_clean5_zpd2` (7 variables) obtiene la mayor ganancia media ($+0.0203 \pm 0.0167$, $\Delta = +0.0298$, $d_z = 2.40$) y alcanza el 49.4 % de la referencia de oráculo ($+0.0411$).
3. **Historial y depuración adicional:** el historial temporal (`FS2`) no aporta señal detectable ($+0.0032$, $p = 0.494$); la depuración adicional (`D2` vs. `FS1`) muestra tendencia favorable ($+0.0098$, $8/10$) aún no significativa ($p = 0.0605$).

No determinado al corte: efecto real de *Dyna-PPO* y del ajuste de hiperparámetros; desempeño al reemplazar θ^* por MSKT/NeuralCD; transferencia a un simulador estructuralmente distinto (p. ej., BKT); impacto en estudiantes reales.

9.2 Riesgos y mitigación

Tabla 11: Matriz de riesgos y estrategias de mitigación.

Riesgo	Impacto	Mitigación
Circularidad variable–simulador	**Alto**	Evaluar la política congelada sobre un simulador de familia distinta (BKT).
Dependencia de θ^* verdadero	**Alto**	Sustituir por estimador aprendido (MSKT/NeuralCD) y repetir el contraste pareado.
Brecha entre título y prototipo	**Alto**	Priorizar *Dyna-PPO* y estimador en Semanas 10–14; acordar alcance final con la asesora.
Potencia estadística	**Medio**	Evaluación confirmatoria con mayor número de corridas y particiones independientes.

9.3 Plan del siguiente sprint (Semanas 10–14)

Tabla 12: Actividades y criterios de aceptación del siguiente sprint.

Actividad	Entregable	Criterio de aceptación	Semana
Modelo del mundo + *Dyna-PPO*	Módulos en `src/` y logs por corrida	Resultados ejecutados y trazados por script versionado	10–11
Búsqueda de hiperparámetros	Registro completo de trials	Espacio de búsqueda y presupuesto fijados antes de ejecutar	12
Evaluación confirmatoria	Tabla con particiones y semillas nuevas	Verificación de criterio enmendado de HG (≥ 40 % oráculo)	13–14

Referencias

Altman, E. (1999). *Constrained Markov decision processes*. Chapman & Hall/CRC.

Birnbaum, A. (1968). Some latent trait models and their use in inferring an examinee's ability. En F. M. Lord & M. R. Novick (Eds.), *Statistical theories of mental test scores* (pp. 397–479). Addison-Wesley.

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum.

Corbett, A. T., & Anderson, J. R. (1994). Knowledge tracing: Modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4(4), 253–278.

Csikszentmihalyi, M. (1990). *Flow: The psychology of optimal experience*. Harper & Row.

Doroudi, S., Aleven, V., & Brunskill, E. (2019). Where's the reward? A review of reinforcement learning for instructional sequencing. *International Journal of Artificial Intelligence in Education*, 29(4), 568–620.

García, J., & Fernández, F. (2015). A comprehensive survey on safe reinforcement learning. *Journal of Machine Learning Research*, 16(42), 1437–1480.

Hake, R. R. (1998). Interactive-engagement versus traditional methods. *American Journal of Physics*, 66(1), 64–74.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.

Janner, M., Fu, J., Zhang, M., & Levine, S. (2019). When to trust your model: Model-based policy optimization. *Advances in Neural Information Processing Systems*, 32.

Kintsch, W. (1998). *Comprehension: A paradigm for cognition*. Cambridge University Press.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.

MINEDU. (2016). *Currículo Nacional de la Educación Básica*. Ministerio de Educación del Perú.

OECD. (2023). *PISA 2022 results (Volume I): The state of learning and equity in education*. OECD Publishing.

Pandey, S., & Karypis, G. (2019). A self-attentive model for knowledge tracing. *Proceedings of EDM 2019*.

Piech, C., et al. (2015). Deep knowledge tracing. *Advances in Neural Information Processing Systems*, 28.

Schulman, J., Moritz, P., Levine, S., Jordan, M., & Abbeel, P. (2016). High-dimensional continuous control using generalized advantage estimation. *ICLR 2016*.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.

Shin, D., et al. (2021). SAINT+: Integrating temporal features for EdNet correctness prediction. *Proceedings of LAK21*.

Sutton, R. S. (1991). Dyna, an integrated architecture for learning, planning, and reacting. *ACM SIGART Bulletin*, 2(4), 160–163.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2.ª ed.). MIT Press.

Vygotsky, L. S. (1978). *Mind in society*. Harvard University Press.

Wang, F., et al. (2020). Neural cognitive diagnosis for intelligent education systems. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(04), 6153–6161.

MATERIAL DE SOPORTE Y TRAZABILIDAD

Anexos

Anexo A. Matriz de consistencia

Tabla 13: Matriz de consistencia al corte de la Semana 9.

Probl.	Obj.	Hipótesis	Variables	Indicador y resultado
PG	OG	HG: PPO con vector depurado supera a vector crudo y políticas base	VI: conjunto de variables y política. VD: ganancia LG	LG: $-0.0095 \rightarrow +0.0203$; $\Delta = +0.0298$ $[+0.0225, +0.0372]$; 49.4 % del oráculo
PE1	OE1	HE1: `zpd_hit` y `abs_gap` son las más informativas	VI: `zpd_hit`, `abs_gap`. VD: transición aprendizaje	$\Delta\mathrm{AUC}$ #1 y #2; $\lvert\mathrm{SHAP}\rvert$ #1 y #4. Parcialmente confirmada
PE2	OE2	HE2: depurar el estado mejora la ganancia	VI: estado limpio vs. completo. VD: ganancia LG	$\Delta = +0.0098$, $p = 0.0605$, $d_z = 0.60$. No confirmada
PE3	OE3	HE3: *Dyna-PPO* ajustado supera a PPO	VI: planificación e HPO. VD: ganancia y eficiencia	Sin evaluar (planificada para Semanas 10–14)

Anexo B. Enlace al último branch y trazabilidad

Rama de entrega: `https://github.com/yasminum/SistemaTutorInteligente/tree/feat/hyperparameter-optimization` — código, datos y registros en el commit `77c6cfe` (compilación LaTeX/PDF de este informe añadida en `docs/`). La rama conserva su denominación original aunque la búsqueda de hiperparámetros quedó programada para la Semana 12.

Tabla 14: Ramas y commits del sprint.

Etapa	Rama	Commit
EDA (Semana 4)	`eda`	`723cbf8`
Variables ZPD (Semana 5)	`feature-engineering`	`b1dd663`
Auditoría y poda (Semana 6)	`data-centric-audit-and-pruning`	`b8795ab`
Importancia y matriz (Semana 7)	`feat/variable-importance-and-consistency-matrix`	`e659281`
Depuración de evidencia (Semana 9)	`feat/hyperparameter-optimization`	`77c6cfe`

Anexo C. Diccionario y decisión por variable

Tabla 15: Variables candidatas del estado–acción y decisión de selección.

Variable	Definición	Decisión
`zpd_hit`	$\mathbf{1}\big[\lvert\theta_k - b_{\text{adj}}\rvert < 0.5\big]$	**Retenida**
`abs_gap`	$\lvert\theta_k - b_{\text{adj}}\rvert$	**Retenida**
`theta_1`, `theta_2`, `theta_3`	Habilidad verdadera por competencia	**Retenidas**
`b_prev_raw`, `u_progress`	Dificultad previa y avance $t/50$	**Retenidas** (sin ablación propia)
`zpd_prox`, `signed_gap`	Proximidad gaussiana y brecha con signo	Descartadas por colinealidad
`sigma_1..3`, `u_acc`, `u_streak`, `tau_1`, `tau_2`, `E_hat`	Columnas constantes sin variación (`n_dead_xt` $= 8$)	Descartadas

Anexo D. Registro individual de corridas

Configuración (`runs_oracle.json`): `n_students` $= 100$, `k_folds` $= 5$, `fold_seed` $= 2026$, `bank_seed` $= 2026$, `seeds` $= [0, 1]$, `train_episodes` $= 1500$. Huellas SHA-256: `code_sha256` $=$ `ed9d8eac...49b1a`, `data_sha256` $=$ `07ed76f0...d4706`.

Tabla 16: Ganancia LG por corrida individual de `D2_clean5_zpd2`.

Corrida	1	2	3	4	5	6	7	8	9	10
D2 LG	-0.0029	$+0.0085$	$+0.0100$	$+0.0044$	$+0.0382$	$+0.0345$	$+0.0496$	$+0.0152$	$+0.0269$	$+0.0185$

Anexo E. Pruebas de no-fuga de datos

Tabla 17: Pruebas automáticas de no-fuga (`python -m src.leakage_checks` y `tests/test_leakage_checks.py`). Resultado: $5/5$ PASS (`leakage_all_pass` $=$ `true`).

Prueba	Propiedad verificada
L1	Ningún estudiante aparece simultáneamente en entrenamiento y validación dentro del mismo *fold*.
L2	El vector de estado en el paso t es invariante ante alteraciones de respuestas futuras ($> t$).
L3	Las variables de acoplamiento ZPD utilizan exclusivamente información previa a la acción.
L4	Las transformaciones de preprocesamiento (`StandardScaler`) se ajustan solo sobre el conjunto de entrenamiento.
L5	Política congelada durante evaluación (parámetros idénticos antes y después de evaluar en validación).